

یادگیری برخط

جلسه پانزدهم: بندیت زمینه‌ای


مرور بندیت دشمنانه



VectorStock.com/13417

VectorStock®

بندیت دشمنانه



For rounds $t = 1, 2, \dots, n$:



Learner selects distribution $P_t \in \mathcal{P}_{k-1}$ and samples A_t from P_t .

Learner observes reward $X_t = x_{tA_t}$.

مسئله بندی دشمنانه

سود

افق زمانی

$$R_n(\pi, x) = \max_{i \in [k]} \sum_{t=1}^n x_{ti} - \mathbb{E} \left[\sum_{t=1}^n x_{tA_t} \right]$$

تعداد دسته‌ها

انتخاب ما

$$R_n^*(\pi) = \sup_{x \in [0,1]^{n \times k}} R_n(\pi, x).$$

الگوریتم EXP3

- 1: **Input:** n, k, η
- 2: Set $\hat{S}_{0i} = 0$ for all i
- 3: **for** $t = 1, \dots, n$ **do**
- 4: Calculate the sampling distribution P_t :

$$P_{ti} = \frac{\exp(\eta \hat{S}_{t-1,i})}{\sum_{j=1}^k \exp(\eta \hat{S}_{t-1,j})}$$

- 5: Sample $A_t \sim P_t$ and observe reward X_t
- 6: Calculate \hat{S}_{ti} :

$$\hat{S}_{ti} = \hat{S}_{t-1,i} + \underbrace{1 - \frac{\mathbb{I}\{A_t = i\} (1 - X_t)}{P_{ti}}}_{\hat{X}_{t,i}}$$

- 7: **end for**

$$\hat{S}_{ti} = \sum_{s=1}^t \hat{X}_{si} \quad P_{ti} = \frac{\exp(\eta \hat{S}_{t-1,i})}{\sum_{j=1}^k \exp(\eta \hat{S}_{t-1,j})} \quad W_t = \sum_{j=1}^k \exp(\eta \hat{S}_{tj})$$

$$\exp(\eta \hat{S}_{ni}) \leq \sum_{j=1}^k \exp(\eta \hat{S}_{nj}) = W_n = W_0 \frac{W_1}{W_0} \cdots \frac{W_n}{W_{n-1}} = k \prod_{t=1}^n \frac{W_t}{W_{t-1}}.$$

$$\begin{aligned} \frac{W_t}{W_{t-1}} &= \sum_{j=1}^k \frac{\exp(\eta \hat{S}_{t-1,j})}{W_{t-1}} \exp(\eta \hat{X}_{tj}) = \sum_{j=1}^k P_{tj} \exp(\eta \hat{X}_{tj}). \\ &\leq 1 + \eta \sum_{j=1}^k P_{tj} \hat{X}_{tj} + \eta^2 \sum_{j=1}^k P_{tj} \hat{X}_{tj}^2 \\ &\leq \exp \left(\eta \sum_{j=1}^k P_{tj} \hat{X}_{tj} + \eta^2 \sum_{j=1}^k P_{tj} \hat{X}_{tj}^2 \right) \end{aligned}$$

$$\exp(\eta \hat{S}_{ni}) \leq k \exp \left(\eta \hat{S}_n + \eta^2 \sum_{t=1}^n \sum_{j=1}^k P_{tj} \hat{X}_{tj}^2 \right)$$

تحليل الگوریتم EXP3

سود
دسته
i

سود
ما

$$\hat{S}_{ni} - \hat{S}_n \leq \frac{\log(k)}{\eta} + \frac{\eta}{2} \sum_{t=1}^n \sum_{j=1}^k P_{tj} (\hat{X}_{tj} - 1)^2$$

تحليل الگوریتم EXP3

سود
دسته
i

سود
ما


$$\hat{S}_{ni} - \hat{S}_n \leq \frac{\log(k)}{\eta} + \frac{\eta}{2} \sum_{t=1}^n \sum_{j=1}^k P_{tj} (\hat{X}_{tj} - 1)^2$$

$$R_n(\pi, x) \leq 2\sqrt{nk \log(k)}.$$

$$\begin{aligned}
\mathbb{E} \left[\sum_{j=1}^k P_{tj} \hat{X}_{tj}^2 \right] &= \mathbb{E} \left[\sum_{j=1}^k P_{tj} \left(1 - \frac{\mathbb{I}\{A_t = j\} y_{tj}}{P_{tj}} \right)^2 \right] \\
&= \mathbb{E} \left[\sum_{j=1}^k P_{tj} \left(1 - 2 \frac{\mathbb{I}\{A_t = j\} y_{tj}}{P_{tj}} + \frac{\mathbb{I}\{A_t = j\} y_{tj}^2}{P_{tj}^2} \right) \right] \\
&= \mathbb{E} \left[1 - 2Y_t + \mathbb{E}_{t-1} \left[\sum_{j=1}^k \frac{\mathbb{I}\{A_t = j\} y_{tj}^2}{P_{tj}} \right] \right] \\
&= \mathbb{E} \left[1 - 2Y_t + \sum_{j=1}^k y_{tj}^2 \right] \\
&= \mathbb{E} \left[(1 - Y_t)^2 + \sum_{j \neq A_t} y_{tj}^2 \right] \\
&\leq k.
\end{aligned}$$

بندیت زمینه‌ای

تعریف بندیت زمینه‌ای
دشمنانه



بندیت زمینه‌ای: انگیزش

● اطلاعات زمینه

● مثال: پیشنهاد فیلم

تعريف بنديت دشمنانه



For rounds $t = 1, 2, \dots, n$:



Learner selects distribution $P_t \in \mathcal{P}_{k-1}$ and samples A_t from P_t .

Learner observes reward $X_t = x_{tA_t}$.

تعريف بندیت دشمنانه

Adversary secretly chooses rewards $(x_t)_{t=1}^n$ with $x_t \in [0, 1]^k$

Adversary secretly chooses contexts $(c_t)_{t=1}^n$ with $c_t \in \mathcal{C}$

For rounds $t = 1, 2, \dots, n$:

Learner selects distribution $P_t \in \mathcal{P}_{k-1}$ and samples A_t from P_t .

Learner observes reward $X_t = x_{tA_t}$.

تعريف بندیت دشمنانه

Adversary secretly chooses rewards $(x_t)_{t=1}^n$ with $x_t \in [0, 1]^k$

Adversary secretly chooses contexts $(c_t)_{t=1}^n$ with $c_t \in \mathcal{C}$

For rounds $t = 1, 2, \dots, n$:

Learner observes context $c_t \in \mathcal{C}$ where \mathcal{C} is an arbitrary fixed set of contexts.

Learner selects distribution $P_t \in \mathcal{P}_{k-1}$ and samples A_t from P_t .

Learner observes reward $X_t = x_{tA_t}$.

تعریف بندیت زمینه‌ای

Adversary secretly chooses rewards $(x_t)_{t=1}^n$ with $x_t \in [0, 1]^k$

Adversary secretly chooses contexts $(c_t)_{t=1}^n$ with $c_t \in \mathcal{C}$

For rounds $t = 1, 2, \dots, n$:

Learner observes context $c_t \in \mathcal{C}$ where \mathcal{C} is an arbitrary fixed set of contexts.

Learner selects distribution $P_t \in \mathcal{P}_{k-1}$ and samples A_t from P_t .

Learner observes reward $X_t = x_{tA_t}$.

چگونه از زمینه استفاده کنیم؟

● بدون زمینه:

$$R_n(\pi, x) \leq 2\sqrt{nk \log(k)}.$$

چگونه از زمینه استفاده کنیم؟

● بدون زمینه:

$$R_n(\pi, x) \leq 2\sqrt{nk \log(k)}.$$

زمینه‌ای چه فایده‌ای دارد؟

روش ۱ استفاده از زمینه: برخورد مستقل با هر زمینه

$$= \mathbb{E} \left[\sum_{c \in \mathcal{C}} \max_{i \in [k]} \sum_{t \in [n]: c_t = c} (x_{ti} - X_t) \right]$$

$$R_n(\pi, x, c) := \sum_{c \in \mathcal{C}} \max_{i \in [k]} \sum_{t: c_t = c} x_{ti} - \mathbb{E} \left[\sum_{t=1}^n X_t \right]$$

$$R_n^*(\pi) = \sup_{x \in [0,1]^{n \times k}, c \in \mathcal{C}} R_n(\pi, x, c)$$

روش ۱: یک EXP3 برای هر زمینه

هر زمینه،
 $n/|C|$ بار

روش ۱: یک EXP3 برای هر زمینه

$$R_{nc} \leq 2 \sqrt{k \sum_{t=1}^n \mathbb{I}\{c_t = c\} \log(k)},$$

هر زمینه،
 $n/|C|$ بار

روش ۱: یک EXP3 برای هر زمینه

$$R_{nc} \leq 2 \sqrt{k \sum_{t=1}^n \mathbb{I}\{c_t = c\} \log(k)},$$

$$R_n = \sum_{c \in \mathcal{C}} R_{nc} \leq 2 \sum_{c \in \mathcal{C}} \sqrt{k \log(k) \sum_{t=1}^n \mathbb{I}\{c_t = c\}}.$$

هر زمینه،
 $n/|\mathcal{C}|$ بار

روش ۱: یک EXP3 برای هر زمینه

$$R_{nc} \leq 2 \sqrt{k \sum_{t=1}^n \mathbb{I}\{c_t = c\} \log(k)},$$

$$R_n = \sum_{c \in \mathcal{C}} R_{nc} \leq 2 \sum_{c \in \mathcal{C}} \sqrt{k \log(k) \sum_{t=1}^n \mathbb{I}\{c_t = c\}}.$$


$$R_n \leq 2 \sqrt{nk|\mathcal{C}| \log(k)}.$$

هر زمینه،
 $n/|\mathcal{C}|$ بار

روش ۱: یک EXP3 برای هر زمینه

$$R_{nc} \leq 2 \sqrt{k \sum_{t=1}^n \mathbb{I}\{c_t = c\} \log(k)},$$

$$R_n = \sum_{c \in \mathcal{C}} R_{nc} \leq 2 \sum_{c \in \mathcal{C}} \sqrt{k \log(k) \sum_{t=1}^n \mathbb{I}\{c_t = c\}}.$$


$$R_n \leq 2 \sqrt{nk|\mathcal{C}| \log(k)}.$$

هر زمینه،
 $n/|\mathcal{C}|$ بار

چرا این مدل سازی خوب است؟

$$\mathbb{E} \left[\sum_{t=1}^n X_t \right] \geq \max_{i \in [k]} \sum_{t=1}^n x_{ti} - 2\sqrt{kn \log(k)}.$$

$$\mathbb{E} \left[\sum_{t=1}^n X_t \right] \geq \sum_{c \in \mathcal{C}} \max_{i \in [k]} \sum_{t \in [n]: c_t = c} x_{ti} - 2\sqrt{kn |\mathcal{C}| \log(k)}.$$

یادگیری برخط

جلسه شانزدهم: بندیت زمینه‌ای

بندیت زمینه‌ای

توابع محدودتر

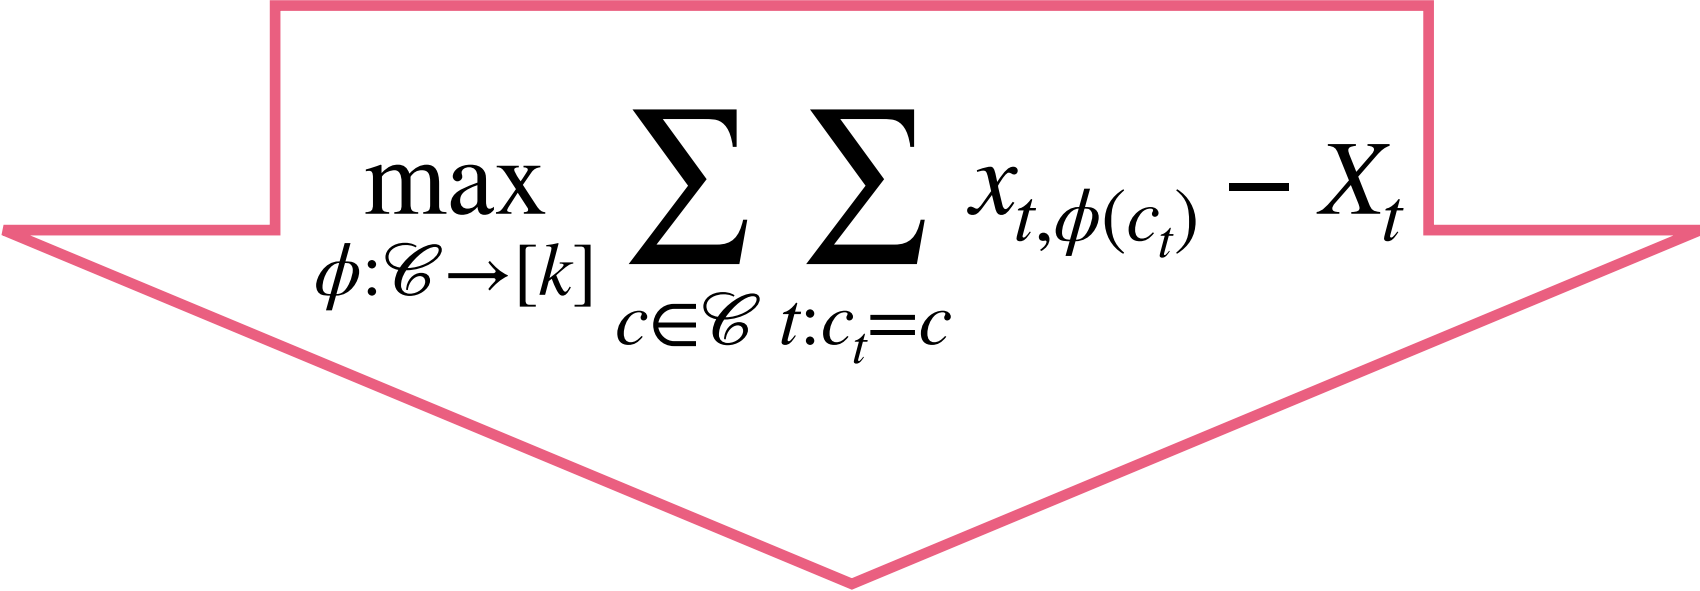


کمی واقعی تر!

$$R_n = \mathbb{E} \left[\sum_{c \in \mathcal{C}} \max_{i \in [k]} \sum_{t \in [n]: c_t = c} (x_{ti} - X_t) \right]$$

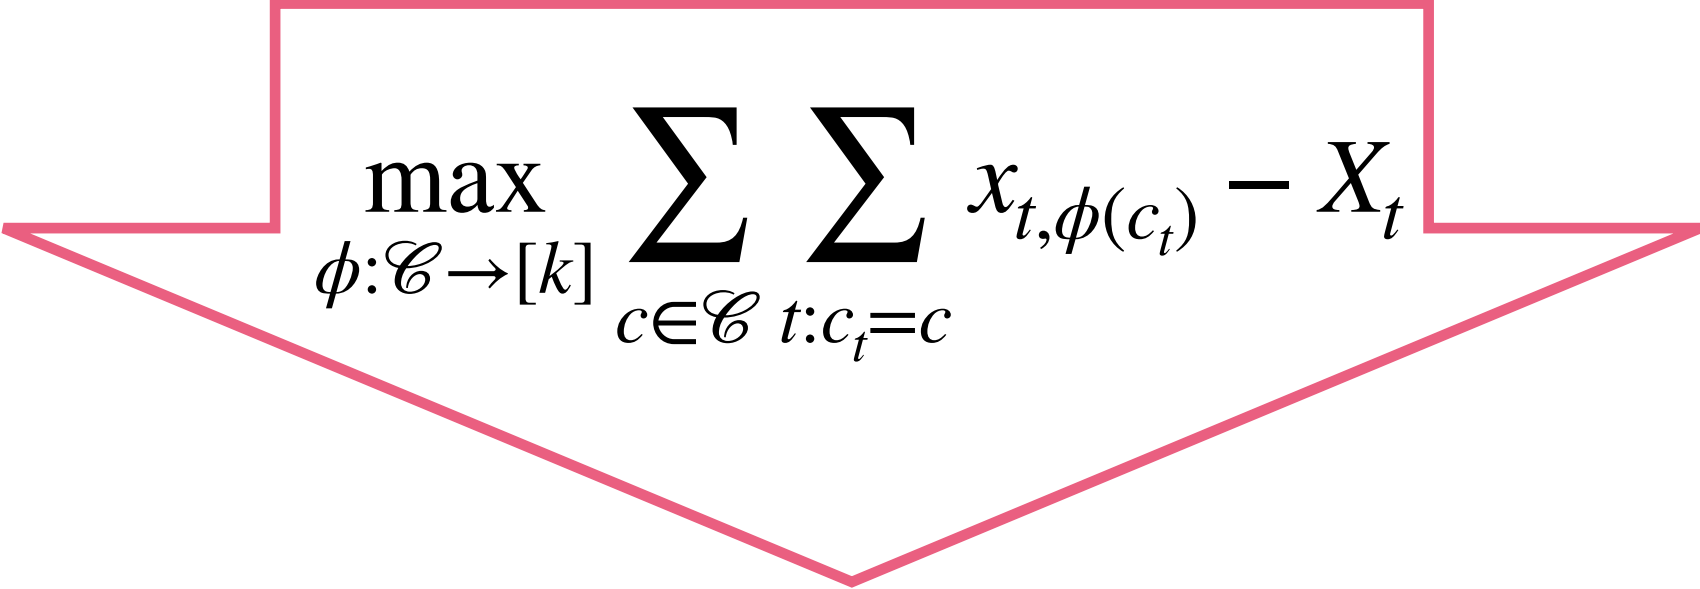
کمی واقعی تر!

$$R_n = \mathbb{E} \left[\sum_{c \in \mathcal{C}} \max_{i \in [k]} \sum_{t \in [n]: c_t = c} (x_{ti} - X_t) \right]$$


$$\max_{\phi: \mathcal{C} \rightarrow [k]} \sum_{c \in \mathcal{C}} \sum_{t: c_t = c} x_{t, \phi(c_t)} - X_t$$

کمی واقعی تر!

$$R_n = \mathbb{E} \left[\sum_{c \in \mathcal{C}} \max_{i \in [k]} \sum_{t \in [n]: c_t = c} (x_{ti} - X_t) \right]$$


$$\max_{\phi: \mathcal{C} \rightarrow [k]} \sum_{c \in \mathcal{C}} \sum_{t: c_t = c} x_{t, \phi(c_t)} - X_t$$

$$R_n = \mathbb{E} \left[\max_{\phi \in \Phi} \sum_{t=1}^n (x_{t\phi(c_t)} - X_t) \right]$$

نمونه‌هایی از Φ

$$\frac{1}{|\mathcal{C}|^2} \sum_{c,d \in \mathcal{C}} (1 - s(c,d)) \mathbb{I} \{ \phi(c) \neq \phi(d) \}$$

نمونه‌هایی از Φ

● (همه توابع

$$\frac{1}{|\mathcal{C}|^2} \sum_{c,d \in \mathcal{C}} (1 - s(c,d)) \mathbb{I} \{ \phi(c) \neq \phi(d) \}$$

نمونه‌هایی از Φ

● (۰) همه توابع

● (۱) به ازای یک افراز از C ، توابعی که به هر زیرمجموعه از افراز یک عدد ثابت نسبت می‌دهند.

$$\frac{1}{|C|^2} \sum_{c,d \in C} (1 - s(c,d)) \mathbb{I} \{ \phi(c) \neq \phi(d) \}$$

نمونه‌هایی از Φ

● (۰) همه توابع

● (۱) به ازای یک افراز از C ، توابعی که به هر زیرمجموعه از افراز یک عدد ثابت نسبت می‌دهند.

● (۲) توابع با تغییرات کوچک

$$\frac{1}{|C|^2} \sum_{c,d \in C} (1 - s(c,d)) \mathbb{I} \{ \phi(c) \neq \phi(d) \}$$

نمونه‌هایی از Φ

● (۰) همه توابع

● (۱) به ازای یک افراز از C ، توابعی که به هر زیرمجموعه از افراز یک عدد ثابت نسبت می‌دهند.

● (۲) توابع با تغییرات کوچک

$$\frac{1}{|C|^2} \sum_{c,d \in C} (1 - s(c,d)) \mathbb{I} \{ \phi(c) \neq \phi(d) \}$$

● (۳) توابع نامزد (مثلاً: یادگیری غیربرخط)

$$\phi_1, \dots, \phi_M : C \rightarrow [k].$$

نمونه‌هایی از Φ

● (۰) همه توابع

● (۱) به ازای یک افراز از C ، توابعی که به هر زیرمجموعه از افراز یک عدد ثابت نسبت می‌دهند.

● (۲) توابع با تغییرات کوچک

$$\frac{1}{|C|^2} \sum_{c,d \in C} (1 - s(c,d)) \mathbb{I} \{ \phi(c) \neq \phi(d) \}$$

● (۳) توابع نامزد (مثلاً: یادگیری غیربرخط)



$$\phi_1, \dots, \phi_M : C \rightarrow [k].$$

بندیت زمینه‌ای

راهنمایی متخصصین



$$\phi_1, \dots, \phi_M : \mathcal{C} \rightarrow \mathbb{P}_k$$

$$R_n = \mathbb{E} \left[\max_{\phi \in \Phi} \sum_t \left(\sum_{i=1}^k \phi(c_t)_i \cdot x_{t,i} - X_t \right) \right]$$


$$R_n = \mathbb{E} \left[\max_{\phi \in \Phi} \sum_{t=1}^n (x_t \phi(c_t) - X_t) \right]$$

$$\phi_1, \dots, \phi_M : \mathcal{C} \rightarrow \mathbb{P}_k$$

$$R_n = \mathbb{E} \left[\max_{\phi \in \Phi} \sum_t \left(\sum_{i=1}^k \phi(c_t)_i \cdot x_{t,i} - X_t \right) \right]$$

$$\phi_1, \dots, \phi_M : \mathcal{C} \rightarrow [k].$$

$$R_n = \mathbb{E} \left[\max_{\phi \in \Phi} \sum_{t=1}^n (x_t \phi(c_t) - X_t) \right]$$



$$\phi_1, \dots, \phi_M : \mathcal{C} \rightarrow \mathbb{P}_k$$

$$R_n = \mathbb{E} \left[\max_{\phi \in \Phi} \sum_t \left(\sum_{i=1}^k \phi(c_t)_i \cdot x_{t,i} - X_t \right) \right]$$

صورت مسئله «بندیت با راهنمایی متخصصین»

Adversary secretly chooses rewards $x \in [0, 1]^{n \times k}$

Experts secretly choose predictions $E^{(1)}, \dots, E^{(n)}$

For rounds $t = 1, 2, \dots, n$:

Learner observes predictions of all experts, $E^{(t)} \in [0, 1]^{M \times k}$.

Learner selects a distribution $P_t \in \mathcal{P}_{k-1}$.

Action A_t is sampled from P_t and the reward is $X_t = x_{tA_t}$.

$$R_n = \mathbb{E} \left[\max_{m \in [M]} \sum_{t=1}^n E_m^{(t)} x_t - \sum_{t=1}^n X_t \right]$$

هدف

ایده



ایده

$$A_t \sim P_t = Q_t E^{(t)}$$



ایده

$$A_t \sim P_t = Q_t E^{(t)}$$

ما

Q_t

متخصصان

$E^{(t)}$

دسته‌ها

ایده

$$A_t \sim P_t = Q_t E^{(t)}$$

ما

Q_t

متخصص‌ها

$E^{(t)}$

دسته‌ها

$$\hat{X}_{ti} = 1 - \frac{\mathbb{I}\{A_t=i\}}{P_{ti}+\gamma} (1 - X_t)$$

ایده

$$A_t \sim P_t = Q_t E^{(t)}$$

ما

Q_t

متخصص‌ها

$E^{(t)}$

دسته‌ها

$$\tilde{X}_t = E^{(t)} \hat{X}_t$$

$$\hat{X}_{ti} = 1 - \frac{\mathbb{I}\{A_t=i\}}{P_{ti}+\gamma} (1 - X_t)$$

$$A_t \sim P_t = Q_t E^{(t)}$$

ما

Q_t

متخصص‌ها

$E^{(t)}$

دسته‌ها

$$\exp \left(\eta \widetilde{X}_{t,m} \right)$$

$$\widetilde{X}_t = E^{(t)} \hat{X}_t$$

$$\hat{X}_{ti} = 1 - \frac{\mathbb{I}\{A_t=i\}}{P_{ti}+\gamma} (1 - X_t)$$

طبق تحلیل الگوریتم
EXP3 داریم:

با احتمال $E^{(t)} Q_t$ انتخاب دسته‌ها

LEMMA 18.2. *For any $m^* \in [M]$, it holds that*

$$\sum_{t=1}^n \tilde{X}_{tm^*} - \sum_{t=1}^n \sum_{m=1}^M Q_{tm} \tilde{X}_{tm} \leq \frac{\log(M)}{\eta} + \frac{\eta}{2} \sum_{t=1}^n \sum_{m=1}^M Q_{tm} (1 - \tilde{X}_{tm})^2.$$


طبق تحلیل الگوریتم
EXP3 داریم:

با احتمال $E^{(t)} Q_t$ انتخاب دسته‌ها

LEMMA 18.2. *For any $m^* \in [M]$, it holds that*


$$\sum_{t=1}^n \tilde{X}_{tm^*} - \sum_{t=1}^n \sum_{m=1}^M Q_{tm} \tilde{X}_{tm} \leq \frac{\log(M)}{\eta} + \frac{\eta}{2} \sum_{t=1}^n \sum_{m=1}^M Q_{tm} (1 - \tilde{X}_{tm})^2.$$

$$R_n \leq \frac{\log(M)}{\eta} + \frac{\eta}{2} \sum_{t=1}^n \sum_{m=1}^M \mathbb{E} \left[Q_{tm} (1 - \tilde{X}_{tm})^2 \right].$$



$$\hat{Y}_{it} = \frac{\mathbb{I}[A_t = i]y_{ti}}{P_{ti}}$$


$$\mathbb{E} \left[\sum_{m=1}^M Q_{tm} (1 - \tilde{X}_{tm})^2 \right]$$




$$\hat{Y}_{ti} = 1 - \hat{X}_{ti}$$

$$\hat{Y}_{it} = \frac{\mathbb{I}[A_t = i] y_{ti}}{P_{ti}}$$

$$\mathbb{E} \left[\sum_{m=1}^M Q_{tm} (1 - \tilde{X}_{tm})^2 \right]$$



$$\mathbb{E} \left[\sum_{m=1}^M Q_{tm} (1 - \tilde{X}_{tm})^2 \right]$$



$$\mathbb{E}_t[\tilde{Y}_{tm}^2] = \mathbb{E}_t \left[\left(\frac{E_{mA_t}^{(t)} y_{tA_t}}{P_{tA_t}} \right)^2 \right]$$

$$\mathbb{E} \left[\sum_{m=1}^M Q_{tm} (1 - \tilde{X}_{tm})^2 \right]$$

ما

Q_t

متخصصها

$E^{(t)}$

دستهها

$y_{ti} = 1 - x_{ti}$

$$\exp\left(\eta \widetilde{X}_{t,m}\right)$$

$$\tilde{X}_t = E^{(t)} \hat{X}_t$$

$$\hat{X}_{ti} = 1 - \frac{\mathbb{I}\{A_t=i\}}{P_{ti}+\gamma} (1 - X_t)$$

$$\begin{aligned} E^{(t)}(1 - \hat{X}_t) \\ = 1 - E^{(t)} \hat{X}_t \\ = 1 - \widetilde{X}_t \end{aligned}$$

$$\tilde{Y}_{tm} = 1 - \tilde{X}_{tm}$$

$$\hat{Y}_{ti} = 1 - \hat{X}_{ti}$$

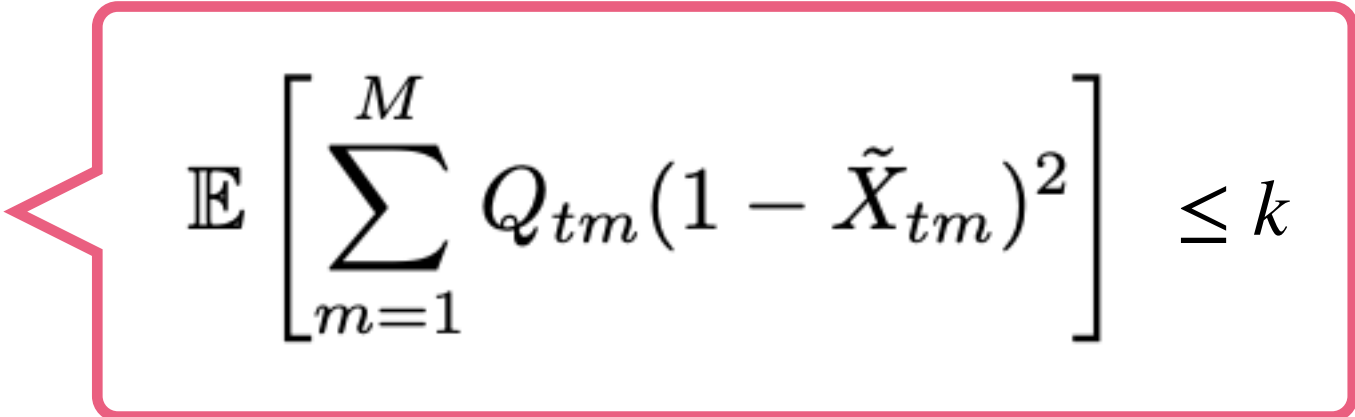
$$\tilde{Y}_t = E^{(t)} \hat{Y}_t$$

$$\hat{Y}_{it} = \frac{\mathbb{I}[A_t = i] y_{ti}}{P_{ti}}$$

$$\mathbb{E}_t[\tilde{Y}_{tm}^2] = \mathbb{E}_t \left[\left(\frac{E_{mA_t}^{(t)} y_{tA_t}}{P_{tA_t}} \right)^2 \right] = \sum_{i=1}^k \frac{\left(E_{mi}^{(t)} y_{ti} \right)^2}{P_{ti}} \leq \sum_{i=1}^k \frac{E_{mi}^{(t)}}{P_{ti}}.$$

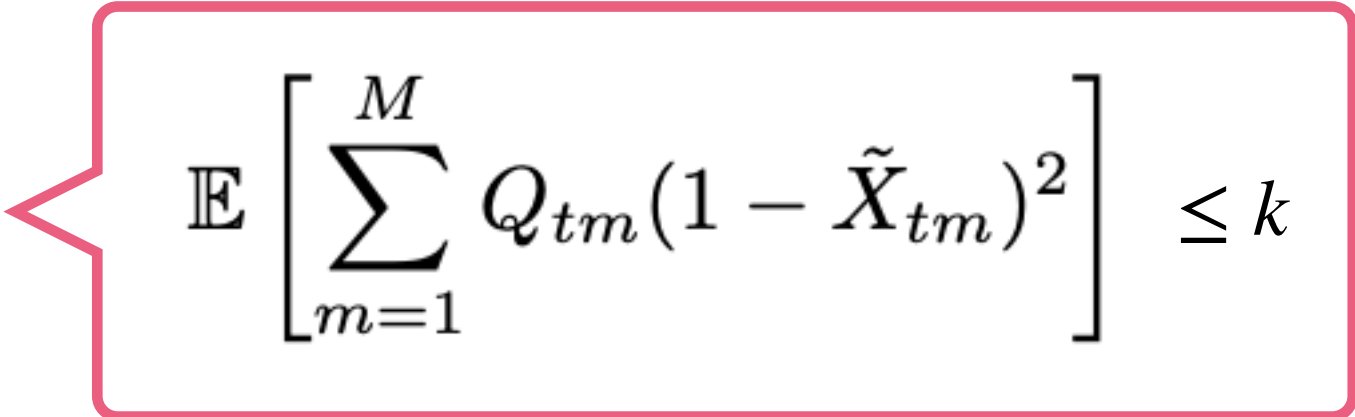
$$\mathbb{E} \left[\sum_{m=1}^M Q_{tm} (1 - \tilde{X}_{tm})^2 \right] \leq \mathbb{E} \left[\sum_{m=1}^M Q_{tm} \sum_{i=1}^k \frac{E_{mi}^{(t)}}{P_{ti}} \right] = \mathbb{E} \left[\sum_{i=1}^k \frac{\sum_{m=1}^M Q_{tm} E_{mi}^{(t)}}{P_{ti}} \right]$$

$$R_n \leq \frac{\log(M)}{\eta} + \frac{\eta}{2} \sum_{t=1}^n \sum_{m=1}^M \mathbb{E} \left[Q_{tm} (1 - \tilde{X}_{tm})^2 \right].$$



$$\mathbb{E} \left[\sum_{m=1}^M Q_{tm} (1 - \tilde{X}_{tm})^2 \right] \leq k$$

$$R_n \leq \frac{\log(M)}{\eta} + \frac{\eta}{2} \sum_{t=1}^n \sum_{m=1}^M \mathbb{E} \left[Q_{tm} (1 - \tilde{X}_{tm})^2 \right].$$



$$\mathbb{E} \left[\sum_{m=1}^M Q_{tm} (1 - \tilde{X}_{tm})^2 \right] \leq k$$

$$\leq \frac{\log(M)}{\eta} + \frac{\eta n k}{2}$$

$$R_n \leq \frac{\log(M)}{\eta} + \frac{\eta}{2} \sum_{t=1}^n \sum_{m=1}^M \mathbb{E} \left[Q_{tm} (1 - \tilde{X}_{tm})^2 \right].$$

$$\mathbb{E} \left[\sum_{m=1}^M Q_{tm} (1 - \tilde{X}_{tm})^2 \right] \leq k$$

$$\leq \frac{\log(M)}{\eta} + \frac{\eta nk}{2} = \sqrt{2nk \log(M)}.$$

$$R_n \leq \frac{\log(M)}{\eta} + \frac{\eta}{2} \sum_{t=1}^n \sum_{m=1}^M \mathbb{E} \left[Q_{tm} (1 - \tilde{X}_{tm})^2 \right].$$

$$\mathbb{E} \left[\sum_{m=1}^M Q_{tm} (1 - \tilde{X}_{tm})^2 \right] \leq k$$

$$\leq \frac{\log(M)}{\eta} + \frac{\eta nk}{2} = \sqrt{2nk \log(M)}.$$

THEOREM 18.1. *Let $\gamma = 0$ and $\eta = \sqrt{2 \log(M)/(nk)}$, and denote by R_n the expected regret of Exp4 defined in Algorithm 11 after n rounds. Then,*

$$R_n \leq \sqrt{2nk \log(M)}. \quad (18.7)$$

$$R_n \leq \sqrt{2nk \log(M)}.$$

$$R_n \leq \sqrt{2nk \log(M)}.$$

● مثال: $\Phi =$ همه توابع از C به $[k]$

$$R_n \leq \sqrt{2nk \log(M)}.$$

● مثال: $\Phi =$ همه توابع از C به $[k]$

$$M = k^C$$

$$R_n \leq \sqrt{2nk \log(M)}.$$

● مثال: $\Phi =$ همه توابع از C به $[k]$

$$M = k^{\mathcal{C}}$$

$$R_n \leq \sqrt{2nk|\mathcal{C}| \log(k)},$$

$$R_n \leq \sqrt{2nk \log(M)}.$$

● مثال: $\Phi =$ همه توابع از C به $[k]$

$$M = k^{\mathcal{C}}$$

$$R_n \leq \sqrt{2nk|\mathcal{C}| \log(k)},$$

● مثال: $\Phi =$ تعدادی تابع

$$R_n \leq \sqrt{2nk \log(M)}.$$

● مثال: $\Phi =$ همه توابع از C به $[k]$

$$M = k^{\mathcal{C}}$$

$$R_n \leq \sqrt{2nk|\mathcal{C}| \log(k)},$$

● مثال: $\Phi =$ تعدادی تابع

$$R_n \leq \sqrt{2nk \log(|\Phi|)}.$$

$$E_t^* = \sum_{s=1}^t \sum_{i=1}^k \max_{m \in [M]} E_{mi}^{(s)}$$

THEOREM 18.3. *Assume the same conditions as in Theorem 18.1, except let $\eta_t = \sqrt{\log(M)/E_t^*}$. Then there exists a universal constant $C > 0$ such that*

$$R_n \leq C \sqrt{E_n^* \log(M)}. \quad (18.14)$$

$$E_t^* = \sum_{s=1}^t \sum_{i=1}^k \max_{m \in [M]} E_{mi}^{(s)}$$

THEOREM 18.1. *Let $\gamma = 0$ and $\eta = \sqrt{2 \log(M)/(nk)}$, and denote by R_n the expected regret of Exp4 defined in Algorithm 11 after n rounds. Then,*

$$R_n \leq \sqrt{2nk \log(M)}. \quad (18.7)$$

THEOREM 18.3. *Assume the same conditions as in Theorem 18.1, except let $\eta_t = \sqrt{\log(M)/E_t^*}$. Then there exists a universal constant $C > 0$ such that*

$$R_n \leq C \sqrt{E_n^* \log(M)}. \quad (18.14)$$

پایان