

**تمرین ۱.** فرض کنید  $f(\cdot)$  تابعی با خروجی اعداد صحیح باشد هم‌چنین فرض کنید هیچ الگوریتم تصادفی وجود ندارد که گراف  $G$  و پارامتر  $0 < \delta \leq 1$  را به عنوان ورودی بگیرد، در زمان چندجمله‌ای بر حسب اندازه‌ی  $G$  و  $\frac{1}{\delta}$  اجرا شود و با احتمال  $1 - \delta$  خروجی آن به این شکل باشد: اگر  $G$  قابل رنگ‌آمیزی با  $k$  رنگ نباشد بگوید "نه" و در غیر این صورت یک  $f(k)$  رنگ‌آمیزی از  $G$  ارائه دهد. با این فرضیات نشان دهید که برای  $k \geq 3$ ، فرمول‌های  $DNF$  با  $k$  مولفه قابل یادگیری کارای  $PAC$  با فرمول‌های  $DNF$  با  $f(k)$  مولفه نیستند.

**پاسخ ۱.** درست همانند اثباتی که برای فرمول‌های  $DNF$  سه مولفه‌ای انجام شد، عمل می‌کنیم. بنابراین باید نشان دهیم که  $S_G$  معرفی شده سازگار است اگر و تنها اگر گراف  $G$  قابل رنگ‌آمیزی با  $k$  رنگ باشد و بتوان یک  $f(k)$ -رنگ‌آمیزی برای آن ارائه داد. ابتدا فرض کنید  $G$  یک گراف  $k$ -رنگ‌پذیر باشد و یک  $f(k)$ -رنگ‌آمیزی برای آن ارائه شده است. بنابراین فرض می‌کنیم راس‌ها را با  $C_1, \dots, C_{f(k)}$  رنگ کرده‌ایم و یک رنگ‌آمیزی مجاز داریم. حال یک فرمول با  $f(k)$  مولفه و سازگار با  $S_G$  براساس این رنگ‌آمیزی ارائه می‌دهیم. مولفه‌ی  $i$ ام،  $T_i$  را عطف حاصل از تمام راس‌هایی که رنگ مخالف  $C_i$  دارند در نظر بگیرید و فرمول موردنظر را قرار دهید  $T = T_1 \vee \dots \vee T_{f(k)}$ . این فرمول با  $S_G$  سازگار است زیرا اول راس  $v$  را در نظر بگیرید، این راس با یکی از رنگ‌ها مثلاً  $C_j$  رنگ شده است بنابراین گزاره‌ی متناظر با آن در مولفه‌ی  $T_j$  صدق می‌کند پس خروجی  $T$  برای این مثال درست خواهد بود. هم‌چنین فرض کنید  $e$  یک یال از گراف باشد که دو راس  $v_i$  و  $v_j$ ،  $i \neq j$  را به یکدیگر وصل می‌کند. چون  $k \geq 3$  بنابراین این دو راس باید رنگ‌های متفاوتی داشته باشند. بنابراین هر کدام از مولفه‌های فرمول را در نظر بگیریم، حداقل یکی از متغیرهای  $x_i$  یا  $x_j$  را دارد، بنابراین گزاره‌ی متناظر با  $e$  را صفر می‌کند، بنابراین یک مثال منفی برای  $T$  خواهد بود. پس  $T$  با  $S_G$  سازگار است.

برعکس فرض کنید  $S_G$  با فرمول  $DNF$ ،  $f(k)$ -مولفه‌ای  $T$  سازگار باشد. راس دلخواه  $v$  از  $G$  را در نظر بگیرید. طبق تعریف  $S_G$ ، گزاره‌ی معادل با  $v$  یک نمونه‌ی مثبت است پس باید در  $T$  صدق کند. بنابراین حداقل یکی از مولفه‌های  $T$  وجود دارد که  $v$  در آن صدق می‌کند. رنگ  $v$  را برابر رنگ متناظر با یکی از این مولفه‌ها قرار می‌دهیم. باید نشان دهیم که این رنگ‌آمیزی، یک رنگ‌آمیزی مجاز است. این نیز واضح است (همانند حالت ۳-رنگ‌آمیزی).

فرض کنید که یک الگوریتم کارای  $PAC$  وجود دارد که به کمک آن می‌توان فرمول‌های  $DNF$  با  $k$  مولفه را به کمک فرمول‌های  $DNF$  با  $f(k)$  مولفه یاد گرفت. گراف دلخواه  $G$  را در نظر بگیرید. مجموعه‌ی  $S_G$  را در زمان چندجمله‌ای می‌توان ساخت. اگر الگوریتم فوق را با توزیع یکنواخت روی  $S_G$  انجام دهیم در زمان چندجمله‌ای با احتمال بالایی می‌توان فرمول  $DNF$  سازگار با  $S_G$  (در صورت وجود) یافت، پس می‌توان یک رنگ‌آمیزی برای گراف  $G$  ارائه کرد که این با فرض این که هیچ الگوریتم تقریبی از زمان چندجمله‌ای برای این کار وجود ندارد، تناقض دارد.

**تمرین ۲.** نوع دیگری از مدل  $PAC$  با دو اوراکل به این شکل است: برای مفهوم  $C \in \mathcal{C}$  توزیع‌های دلخواه و جدا از هم  $D_c^+$  روی نمونه‌های مثبت و  $D_c^-$  روی نمونه‌های منفی وجود دارد. الگوریتم یادگیری به اوراکل‌های دسترسی  $EX(c, D_c^+)$  و  $EX(c, D_c^-)$  دسترسی دارد که در واحد زمان به ترتیب یک نمونه‌ی تصادفی مثبت و منفی را خروجی می‌دهند. برای پارامتر خطای  $\epsilon$ ، الگوریتم یادگیری باید فرضیه‌ای ارائه دهد

$$\text{که } \Pr_{x \in D_c^-}[h(x) = 1] \leq \epsilon \text{ و } \Pr_{x \in D_c^+}[h(x) = 0] \leq \epsilon$$

فرض کنید  $\mathcal{C}$  یک کلاس مفهوم دلخواه و  $\mathcal{H}$  کلاس نمایش باشد و  $h_0$  و  $h_1$  به ترتیب نمایش تابع‌های ثابت ۰ و ۱ باشند. ثابت کنید  $\mathcal{C}$  با استفاده از کلاس نمایش  $\mathcal{H}$  قابل یادگیری کارای  $PAC$  است اگر و تنها اگر در مدل جدید با استفاده از کلاس نمایش  $\mathcal{H} \cup \{h_0, h_1\}$  قابل یادگیری  $PAC$  باشد.

**پاسخ ۲.** ابتدا فرض کنید مساله قابل یادگیری کارای  $PAC$  با تعریف اول (یک اوراکل) باشد. باید الگوریتمی با تعریف دوم ارائه کنیم. ابتدا در نظر داشته باشید که با یک درخواست به هر کدام از اوراکل‌های  $EX(c, D_c^+)$  یا  $EX(c, D_c^-)$  می‌توان فهمید که آیا یکی از دو مجموعه‌ی نمونه‌های مثبت و یا منفی تهی است یا خیر که در صورت تهی بودن می‌توان از نمایش‌های  $h_0$  و  $h_1$  استفاده کرد. بنابراین فرض می‌کنیم که هیچ کدام از دو مجموعه تهی نباشد. توزیع  $\mathcal{D}$  را به صورت زیر تعریف می‌کنیم:

$$\mathcal{D} = \frac{1}{2}(\mathcal{D}_c^+ + \mathcal{D}_c^-)$$

با توجه به این که توزیع‌های  $\mathcal{D}_c^+$  و  $\mathcal{D}_c^-$  توزیع‌های احتمال هستند، توزیع  $\mathcal{D}$  نیز یک توزیع احتمال ارائه می‌دهد. اگر الگوریتم را روی این توزیع و با پارامترهای  $\epsilon$  و  $\delta$  اجرا کنیم با احتمال  $1 - \delta$  فرضیه‌ی  $h \in \mathcal{H}$  را خروجی می‌دهد به طوری که داریم

$$\Pr_{x \sim \mathcal{D}}[c(x) \neq h(x)] \leq \epsilon$$

که نتیجه می‌دهد

$$\Pr_{x \in \mathcal{D}_c^+}[h(x) = 0] \leq \Pr_{x \sim \mathcal{D}}[c(x) \neq h(x)] \leq \epsilon$$

$$\Pr_{x \in \mathcal{D}_c^-}[h(x) = 1] \leq \Pr_{x \sim \mathcal{D}}[c(x) \neq h(x)] \leq \epsilon$$

بنابراین  $h$  در تعریف دوم فرضیه‌ی مطلوب است. بنابراین تنها کافی است توزیع  $\mathcal{D}$  را شبیه سازی کنیم که با توجه به تعریف آن، از یک توزیع یکنواخت روی  $\{0, 1\}$  و سپس استفاده از توزیع متناظر  $\mathcal{D}_c^+$  یا  $\mathcal{D}_c^-$  حاصل می‌شود.

برعکس فرض کنید یک الگوریتم با تعریف دوم داریم و می‌خواهیم الگوریتمی سازگار با تعریف اول برای توزیع  $\mathcal{D}$  و پارامترهای  $\epsilon$  و  $\delta$  ارائه دهیم. توزیع  $\mathcal{D}$  را می‌توان به صورت ترکیب دو توزیع  $\mathcal{D} = \mathcal{D}_c^+ + \mathcal{D}_c^-$  نوشت که به ترتیب نمونه‌های مثبت و منفی را در بر می‌گیرند. فرض کنید یک نمونه‌ی مثبت از اوراکل  $EX(c, \mathcal{D})$  می‌خواهیم به دست آوریم. احتمال این که بعد از  $m$  بار صدا زدن اوراکل هنوز نمونه‌ی مثبتی به دست نیامده باشد را حساب می‌کنیم. فرض کنید وزن مجموعه‌ی نقاط مثبت تحت توزیع  $\mathcal{D}$  برابر  $\alpha$  باشد. بنابراین احتمال این که با هر بار صدا زدن اوراکل نمونه‌ی منفی دریافت کنیم برابر خواهد بود با  $(1 - \alpha)$  پس بعد از  $m$  بار فراخوانی با احتمال  $(1 - \alpha)^m$  هنوز هیچ نمونه‌ی مثبتی نخواهیم داشت. اگر  $\alpha > \epsilon$  باشد می‌خواهیم که خطا کمتر از  $\delta$  شود. بنابراین داریم:

$$(1 - \alpha)^m \leq e^{-\alpha m} \leq e^{-\epsilon m} \leq \delta \Rightarrow m \geq \frac{1}{\epsilon} \log \frac{1}{\delta}$$

بنابراین اگر با  $\frac{1}{\epsilon} \log \frac{1}{\delta}$  فراخوانی اوراکل هیچ نتیجه‌ی مثبتی حاصل نشود می‌توان فرض کرد که مجموعه‌ی مقادیر مثبت تهی است در این صورت با احتمال  $1 - \delta$  حداکثر خطای  $\epsilon$  خواهیم داشت. به همین ترتیب برای مقادیر منفی می‌توان چنین نتیجه‌ای گرفت.

الگوریتم اولیه که با دو اوراکل کار می کند را  $L$  می نامیم. الگوریتم جدید را به این شکل ارائه می دهیم: در هر مرحله که  $L$  به یکی از دو اوراکل درخواست می دهد که یک نمونه جدید بگیرد، مثلاً به اوراکل  $EX(c, \mathcal{D}_c^+)$  درخواست می دهد، از اوراکل  $EX(c, \mathcal{D})$  یک نمونه می گیریم اگر نمونه مثبت بود آن را برمی گردانیم، و اگر منفی بود دوباره به اوراکل درخواست می دهیم. این کار را حداکثر  $\frac{1}{\epsilon} \log \frac{1}{\delta}$  بار انجام می دهیم. اگر بعد از این مرحله، هیچ نمونه‌ی مثبتی دریافت نشده بود و در مرحله‌ی اول بود (یعنی اولین بار بود که  $L$  درخواست نمونه‌ی مثبت داده بود) می گوئیم که نمونه‌های مثبت تهی است و اگر مرحله‌ی اول نبود و قبلاً اوراکل درخواست نمونه مثبت داده بود و دریافت کرده بود، آخرین نمونه‌ی مثبت را برمی گردانیم. برای نمونه‌های منفی نیز به همین منوال عمل می کنیم. به این ترتیب الگوریتم  $L$  با احتمال  $\delta - 1$  یک فرضیه‌ی  $h$  را خروجی می دهد که خطای آن روی نمونه‌های مثبت و منفی  $\epsilon$  است. بنابراین خطای کل حداکثر  $2\epsilon$  خواهد بود. چون الگوریتم برای هر  $\epsilon$  دلخواه به درستی عمل می کند اگر از ابتدا  $\epsilon/2$  را در نظر می گرفتیم، خطای نهایی برابر  $\epsilon$  می شد.

در نهایت الگوریتم فوق در زمان چندجمله‌ای اجرا خواهد شد. چون  $L$  در زمان چندجمله‌ای اجرا خواهد شد و الگوریتم جدید در هر مرحله از  $L$  حداکثر  $\frac{1}{\epsilon} \log \frac{1}{\delta}$  کار انجام می دهد که چندجمله‌ای است بنابراین در نهایت حاصل ضرب دو چندجمله‌ای زمان اجرای الگوریتم خواهد بود که خود یک چندجمله‌ای است.

**تمرین ۳.** در تعریف دومی که برای مدل  $PAC$  ارائه شده، به الگوریتم یادگیری اجازه داده می شد که در زمان چندجمله‌ای برحسب  $n$  و  $size(c)$  نیز باشد و  $size(c)$  را هم به عنوان ورودی بگیرد. ثابت کنید این ورودی در واقع مورد نیاز نیست: اگر الگوریتم یادگیری کارای  $PAC$  وجود داشته باشد که  $size(c)$  را به عنوان ورودی می گیرد آن گاه الگوریتم یادگیری کارای  $PAC$  برای  $\mathcal{C}$  بدون ورودی  $size(c)$  نیز وجود دارد.

پاسخ این تمرین براساس مراجع [۲] و [۱] به دست آمده است.

**پاسخ ۳.** با توجه به این که اطلاعی از اندازه‌ی مفهوم نداریم، باید الگوریتم موجود را برای اندازه‌های مختلفی از مفهوم اجرا کنیم تا نتیجه‌ی مطلوب حاصل شود. بنابراین باید معیاری برای سنجیدن فرضیه‌های خروجی الگوریتم داشته باشیم. بنابراین  $\epsilon > 0$ ،  $\delta > 0$  و  $i \geq 1$  را دلخواه بگیرید و تعریف کنید:

$$m = \left\lceil \frac{32}{\epsilon} (i \log 2 + \log \frac{2}{\delta}) \right\rceil$$

فرض کنید  $S$  مجموعه‌ای شامل  $m$  عضو است که از اوراکل  $EX(c, \mathcal{D})$  به دست آمده است. فرضیه‌ی  $h$  را سازگار می گوئیم اگر خطای آن روی مجموعه‌ی  $S$  حداکثر  $\frac{3}{4}\epsilon$  باشد (یعنی حداکثر در تعداد  $\frac{3}{4}\epsilon$  نمونه از مجموعه‌ی  $S$ ،  $h$  با  $c$  مخالف باشد) در غیر این صورت می گوئیم  $h$  ناسازگار است.

ابتدا واقعیت‌هایی را در مورد سازگاری و ناسازگاری  $h$  با تعریف فوق به دست می آوریم. فرض کنید خطای  $h$  روی کل فضای مورد بحث (خطای واقعی)، بزرگتر یا مساوی  $\epsilon$  باشد، در این صورت در مورد سازگاری  $h$  نسبت به توزیع  $\mathcal{D}$  داریم:

$$\Pr[h \text{ سازگار باشد}] = \Pr[S \text{ روی } h \text{ خطای } \leq \frac{3}{4}\epsilon]$$

از طرفی طبق فرض می‌دانیم خطای واقعی  $h$  بزرگتر از  $\epsilon$  است، بنابراین:

$$\leq \Pr[S \leq \frac{3}{4}(h \text{ خطای واقعی})]$$

از نامساوی چرنوف داریم:

$$\leq \exp\left(-\frac{m}{4}(h \text{ خطای واقعی})^2\right)$$

با جایگذاری  $m$  داریم:

$$= \exp\left(-\frac{h \text{ خطای واقعی}}{\epsilon} \log \frac{3^{i+1}}{\delta}\right) \leq \exp\left(-\log \frac{3^{i+1}}{\delta}\right) = \frac{\delta}{3^{i+1}}$$

به همین ترتیب می‌توان نشان داد با فرض این که خطای واقعی  $h$  کمتر یا مساوی با  $\frac{\epsilon}{3}$  باشد آن گاه احتمال این که  $h$  نسبت به توزیع  $D$  ناسازگار باشد کمتر مساوی با  $\frac{\delta}{3^{i+1}}$  است.

اکنون فرض کنید الگوریتم  $L$  وجود دارد که  $\epsilon$ ،  $\delta$  و  $\text{size}(c)$  را به عنوان ورودی می‌گیرد و در زمان چندجمله‌ای با احتمال  $1 - \delta$  فرضیه‌ی  $h$  را خروجی می‌دهد که حداکثر خطای  $\epsilon$  دارد. الگوریتم جدید  $L'$  را به این شکل تعریف می‌کنیم: با  $i = 1$  شروع می‌کنیم و ورودی‌های  $\frac{\epsilon}{3}$ ،  $\frac{1}{4}$  و  $\delta = \frac{1}{4^{\log \frac{1}{\delta}}}$  را به عنوان ورودی به الگوریتم  $L$  می‌دهیم. الگوریتم فرضیه‌ی  $h_i$  را به عنوان خروجی می‌دهد که با احتمال  $\frac{1}{4}$  حداکثر خطای  $\frac{\epsilon}{3}$  دارد. مجموعه‌ی  $S_i$  شامل  $m_i = \lceil \frac{3^i}{\epsilon}(i \log 3 + \log \frac{1}{\delta}) \rceil$  نمونه را در نظر بگیرید. اگر  $h_i$  با  $S_i$  سازگار بود، آن را به عنوان خروجی الگوریتم برمی‌گردانیم و در غیر این صورت مقدار  $i$  را یک واحد افزایش می‌دهیم و دوباره همین کار را انجام می‌دهیم. باید نشان دهیم الگوریتم  $L'$  یک الگوریتم یادگیری کارای PAC برای مساله‌ای است که  $L$  آن را یاد می‌گیرد.

فرض کنید  $\tilde{s}$  بزرگتر از  $\text{size}(c)$  باشد. اگر فرضیه‌ی  $h_i$  دارای خطای حداقل  $\frac{\epsilon}{3}$  باشد در این صورت با احتمال حداکثر  $\frac{\delta}{4^{i+1}} \leq \frac{\delta}{4^i} \leq \frac{1}{4}$  ناسازگار خواهد بود و بنابراین با احتمال حداقل  $\frac{3}{4}$  سازگار است. بنابراین احتمال این که  $h$  سازگار باشد بزرگتر مساوی خواهد بود با  $\frac{3}{4} \times \frac{1}{4} = \frac{3}{16}$ . بنابراین احتمال این که الگوریتم برای  $\tilde{s} \geq \text{size}(c)$  به پایان نرسد برابر خواهد بود با  $\frac{5}{8}$ . قرار دهید  $j = \lceil \frac{\log \frac{5}{8}}{\log \frac{3}{4}} \rceil$ . احتمال این که بعد از  $j$  بار

اجرای حلقه در الگوریتم  $L'$  برنامه به پایان نرسیده باشد حداکثر برابر خواهد بود با

$$\left(\frac{5}{8}\right)^j \leq \left(\frac{5}{8}\right)^{\frac{\log \frac{5}{8}}{\log \frac{3}{4}}} = \exp\left(\frac{\log \frac{5}{8}}{\log \frac{3}{4} \log \frac{5}{8}}\right) = \frac{\delta}{4}$$

اما چه زمانی  $\tilde{s} \geq \text{size}(c)$  اتفاق می‌افتد:

$$\begin{aligned} \tilde{s} \geq \text{size}(c) &\iff \frac{3^{i-1}}{4^{\log \frac{1}{\delta}}} \geq \text{size}(c) \\ &\iff \frac{i-1}{\log \frac{3}{4}} \geq \log \text{size}(c) \\ &\iff i \geq 1 + (\log \text{size}(c)) \log \frac{4}{3} \end{aligned}$$

بنابراین با احتمال حداقل  $1 - \frac{\delta}{4}$  الگوریتم  $L'$  بعد از حداکثر  $j' = \lceil 1 + (\log \text{size}(c)) \log \frac{4}{3} \rceil + j$  بار اجرای حلقه متوقف خواهد شد. که فرضیه‌ی خروجی با احتمال حداکثر  $\frac{\delta}{4^{j'+1}} \leq \frac{\delta}{4^{j+1}}$  خطایی بیشتر از  $\epsilon$  خواهد داشت. بنابراین الگوریتم  $L'$  با احتمال  $1 - \delta$  حداکثر خطای  $\epsilon$  خواهد داشت.

زمان اجرای الگوریتم فوق چندجمله‌ای از اندازه‌ی مفهوم،  $\epsilon$  و  $\delta$  خواهد بود. زیرا تعداد اجرای حلقه بعد از  $n$  بار به پایان می‌رسد که  $n$  یک چندجمله‌ای از  $\delta$  و اندازه‌ی مفهوم است. از طرفی در هر بار اجرای حلقه، یک بار الگوریتم  $L$  فراخوانی می‌شود که طبق فرض در زمان چندجمله‌ای اجرای می‌شود. آزمودن فرضیه‌ی خروجی توسط الگوریتم  $L$  به وسیله‌ی  $S$  نیز در زمان چندجمله‌ای صورت می‌پذیرد. بنابراین در نهایت زمان اجرا حاصل ضرب دو چندجمله‌ای است که خود یک چندجمله‌ای خواهد بود.

## مراجع

- [۱] Haussler, David and Kearns, Michael and Littlestone, Nick and Warmuth, K. Manfred *Equivalence of Models for Polynomial Learnability*. Information and Computation 95, 129-161 (1991)
- [۲] Mohri, Mehryar *Course: Foundations of Machine Learning*. Fall 2014.